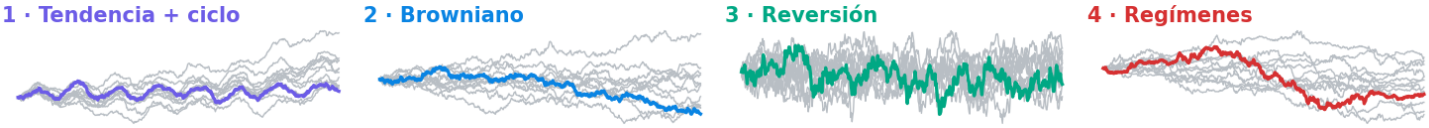
Agentes de Deep RL para trading de un activo

Óscar Romero Quincoces · Fernando Dapena Tauste · Daniel García López · Máster MIAX · Aprendizaje por Refuerzo · Noviembre 2026



1. Diseño experimental

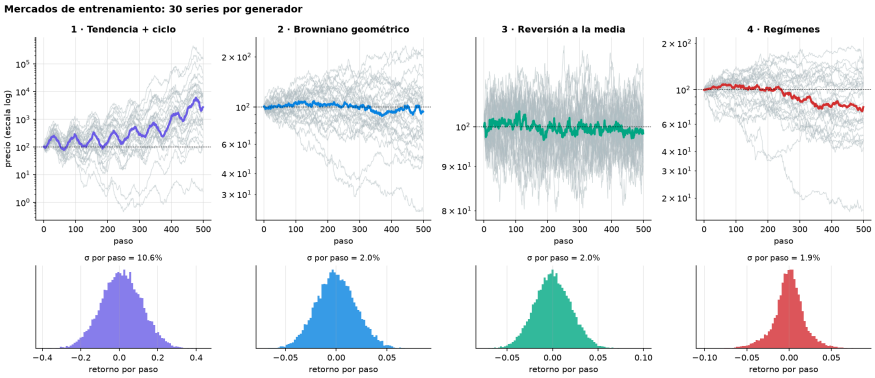


Fig. 1. 30 series de 500 precios por generador e histograma de retornos.

Entorno del enunciado sin cambios: estado (`tendencia, posición`), acciones vender / mantener / comprar, comisión 0,1 % y recompensa = variación del precio con posición menos costes. Cada episodio usa una **serie nueva**; validación en 100 series y **test en 200, evaluadas una sola vez** con la política greedy y 5 semillas, las mismas que el Taller 1 para comparar con Q-Learning y SARSA (D-0.1).

- **Redes (PyTorch, D-0.2).** Lo más simples posible: entrada `[tendencia/σ, posición]` → 64 ReLU. **DQN:** 3 valores Q, memoria de 20 000 transiciones, lote 128, un paso cada 4 y red objetivo cada 500. **A3C:** 3 procesos asíncronos sobre pesos y Adam compartidos, `t_max` = 20, mismo número de pasos de entorno que DQN.
- **Normalización (D-1.1).** La tendencia y la recompensa se dividen por su σ de train. Sin ella el mercado de reversión no opera (+2,3 % frente a +31,4 % en validación).
- **Métricas.** Mediana del retorno (robusta al x1000 del mercado 1); además Sharpe, drawdown y operaciones. **Convergencia:** primer episodio que recorre el 90 % del camino en la curva greedy de validación (D-0.3).
- **Ajuste por etapas con margen de ruido (D-2.3).** Un parámetro cada vez; un valor solo cambia si mejora más que ~2 errores estándar (25 % del múltiplo en 1; 2 puntos en 3; 10 en 2 y 4). Así no se elige el azar en los mercados sin señal.

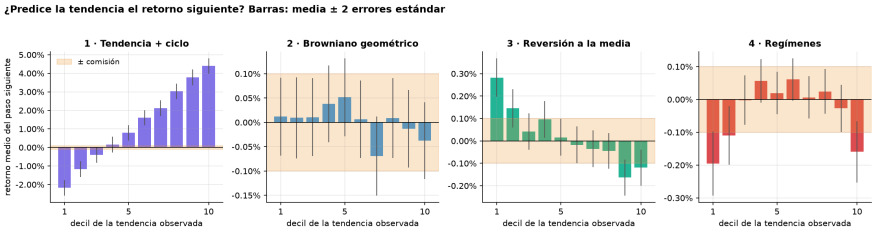


Fig. 2. Retorno siguiente por decil de tendencia.

Estrategia esperada: seguir la tendencia en 1, comprar caídas en 3 y **no operar** en 2 y 4, donde la señal no cubre la comisión. Por eso añadimos **no operar** y dos **reglas de un umbral** como referencia: son el listón real.

2. Resultados por mercado

	1 Tendencia + ciclo	2 Browniano	3 Reversión	4 Regímenes
Aleatorio	x4.3	-19.4%	-17.2%	-22.0%
Buy & hold	x33.6	-3.5%	-0.3%	-12.5%
No operar	+0.0%	**+0.0%**	+0.0%	**+0.0%**
Regla tendencia	**x630.4**	-4.4%	-22.3%	-10.5%
Regla reversión	-50.1%	-4.8%	**+29.2%**	-10.6%
Q-Learning (T1)	x502.3	**+0.0%**	+27.0%	**+0.0%**
SARSA (T1)	x471.6	**+0.0%**	+27.0%	**+0.0%**
DQN	**x299.8**	**-3.9%**	**+20.5%**	**+0.0%**
A3C	**x374.6**	**-4.5%**	**+13.8%**	**+0.0%**

Fig. 3. Mediana del retorno en test (200 series; DQN y A3C, mediana de 5 semillas). Recuadro = mejor del mercado.

- **Ningún agente deep RL gana en ningún mercado.** Gana una regla simple (x630,4; +29,2 %) o no operar (0 %).
- Donde hay señal **baten con claridad a buy & hold** (x33,6; −0,3 %) y al aleatorio.
- **Q-Learning del Taller 1 queda por encima** (x502,3; +27,0 %): con 2 variables discretizar basta.

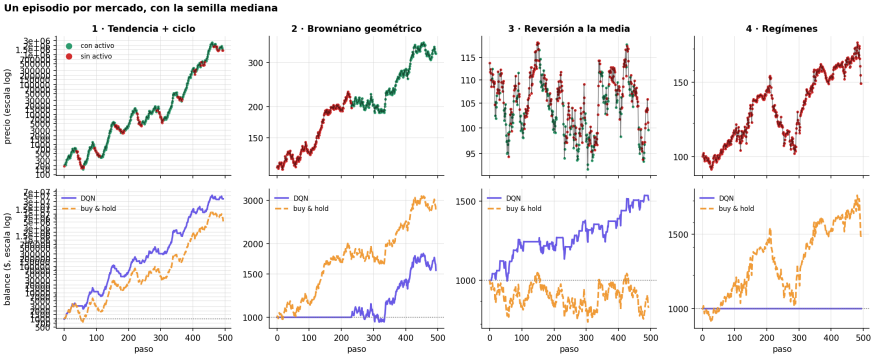
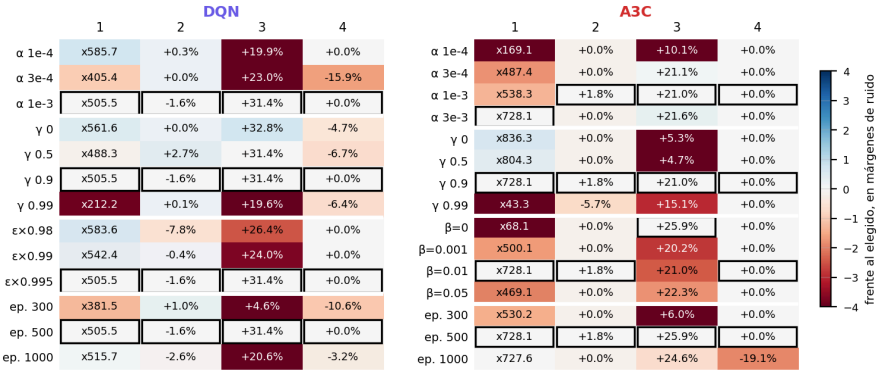


Fig. 4. Un episodio de test por mercado: posición del DQN y balance frente a buy & hold.

¿Es la estrategia esperada? 1: sí, sigue la tendencia, aunque opera de más (44 operaciones). **3:** sí, compra tras caídas y vende tras subidas. **2:** no; entra y se queda (como buy & hold, −3,9 %). **4:** no opera (0 %), lo correcto frente a −12,5 % de buy & hold. A3C aprende lo mismo y no opera en las 5 semillas del 4.

3. DQN frente a A3C



Validación, mediana de 3 semillas. Recuadro = valor elegido (A3C: por mercado).

Fig. 5. Validación de cada valor probado; recuadro = elegido.

DQN: $\alpha = 10^{-3}$, $\gamma = 0{,}9$, ε 1 → ×0,995 por episodio, 500 episodios. **Ningún cambio supera el margen**; $\gamma = 0{,}99$ es claramente peor (x212). **A3C:** ε no existe (política estocástica), se ajusta la entropía β. Solo superan el margen $\alpha = 0{,}003$ en 1 (x538 → x728) y $\beta = 0$ en 3 (+21,0 → +25,9 %); $\gamma = 0{,}99$ hunde el 1 a x43.

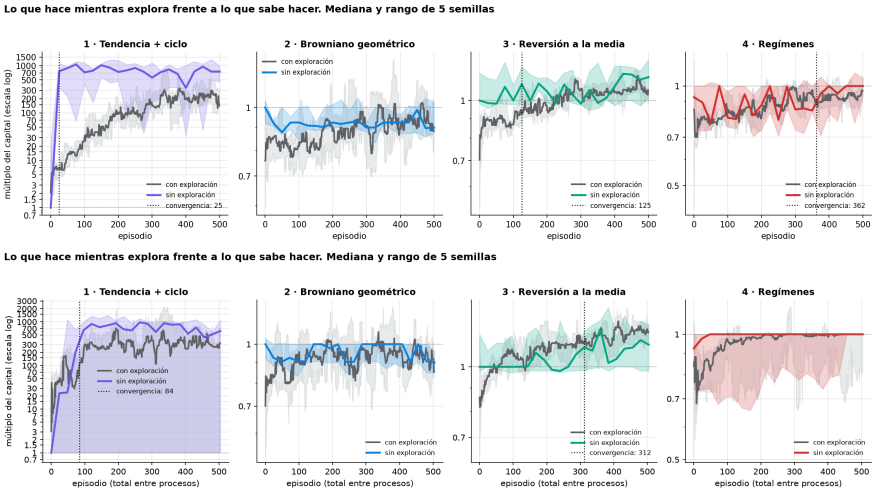


Fig. 6. Curva con exploración frente a greedy en validación (mediana y rango de 5 semillas): DQN arriba, A3C abajo.

Mercado 1 · 3	DQN	A3C
Test (mediana)	x299,8 · **+20,5 %**	**x374,9** · +13,8 %
Convergen	**5/5 · 5/5**	4/5 · 3/5
Episodios	**25 · 125**	84 · 312
Segundos	**1,4** · 7,5	2,4 · **6,4**
Entreno total	33,0 s	**9,9 s**

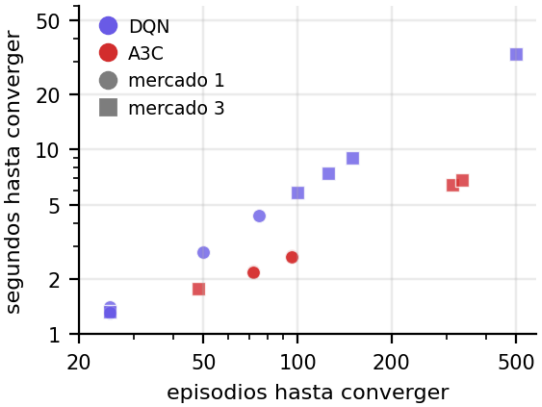


Fig. 7. Episodios frente a segundos hasta converger, por semilla.

Lectura: rendimiento **empatado** (en 1 la diferencia es del orden del margen; DQN gana en 3). A3C es **x3,4 más rápido por episodio**, pero DQN converge en menos episodios y en todas las semillas: **hasta converger tardan lo mismo**.

4. Más allá de los mínimos

	1 Tendencia + ciclo	2 Browniano	3 Reversión	4 Regímenes
+20 retornos	**+0.40 5/5**	-0.07 0/5	**+0.09 4/5**	+0.04 3/5
+MA30 y volatilidad	-0.46 1/5	-0.03 1/5	**+0.25 5/5**	**+0.13 5/5**
Double DQN	-0.06 1/5	+0.00 2/5	**+0.03 3/5**	+0.00 2/5
Recompensa log	+0.22 4/5	+0.01 3/5	+0.00 3/5	+0.05 3/5
Placebo (sin tendencia)	-2.52 0/5	+0.05 4/5	-0.16 0/5	+0.00 2/5
Mezcla 4 mercados	-0.20 1/5	+0.00 2/5	-0.16 1/5	-0.09 0/5
A2C (vs A3C)	+0.09 3/5	-0.05 1/5	+0.00 2/5	+0.00 1/5

Fig. 8. Ventaja log emparejada frente al DQN base en 400 series nuevas; recuadro = supera el margen. Posterior al test: no sustituye al resultado oficial (D-2.4).

- **Lo que ve el agente pesa más que el algoritmo:** añadir 20 retornos lleva el 1 de x348 a x548; MA30 + volatilidad, el 3 de +16,8 a +47,9 % y el 4 a +7,6 %.
- Double DQN solo mejora en 3; **dueling, quitar la red objetivo o recortar la recompensa, nada**. A2C no mejora a A3C.
- **Placebo** sin tendencia: solo compra y mantiene. **Comisión 0,5 %:** de 69 a 1 operación en 3.
- **S&P 500** (train 2017–21, test 2024–25): +12,1 % frente a +43,8 % de buy & hold.

5. Análisis crítico y conclusiones

Limitaciones

- **Estado de 2 variables:** limita más que el algoritmo; con él una tabla basta y la red no aporta.
- **5 semillas y márgenes descriptivos**, no tests de significación. La dispersión es grande (DQN x228–x558 en 1).
- **El test ya se había visto** al probar mejoras: las cifras de §4 y los «mejores puntos» se miden aparte, en series nuevas.
- **Mercados sintéticos** y un S&P 500 de una sola trayectoria, sin spread ni deslizamiento.
- A3C no es reproducible bit a bit; los tiempos solo se comparan en el mismo equipo.

Conclusiones

1. DQN y A3C **aprenden la estrategia esperada** donde hay señal (1 y 3) y **no operan** en 4; fallan en el browniano.
2. **No superan a reglas de un umbral ni a los tabulares**: el problema es demasiado simple para la red.
3. **DQN ≈ A3C** en rendimiento; A3C entrena más rápido, DQN converge en menos episodios y con menos varianza.
4. El ajuste apenas importa salvo γ y normalizar; **lo que más mejora es enriquecer el estado**.
5. Quedarse con el mejor punto de validación (x480,3 y +30,1 % en A3C) es la mejora más prometedora a confirmar.